

Лабораторная работа 1.

Критерий согласия Пирсона

Теоретические сведения

Теория вероятностей и математическая статистика занимаются анализом закономерностей случайных массовых явлений. Предметом математической статистики является изучение случайных величин (или случайных событий, процессов) по результатам наблюдений.

Множество значений результатов наблюдений над одной и той же СВ ξ при одних и тех же условиях называется **выборкой**. Элементы выборки называются **выборочными значениями**. Количество проведенных наблюдений называется **объемом выборки**. Разность W между максимальным и минимальным элементами называется **размахом выборки**: $W = x_{\max} - x_{\min}$.

Пусть имеется выборка объема n : $x_1; x_2; \dots; x_n$. Если в выборке объема n элемент x_i встречается n_i раз, число n_i называется **частотой** выборочного значения x_i , а $\frac{n_i}{n}$ – **относительной частотой**. Очевидно, что $\sum_{i=1}^k n_i = n$, где k – число различных элементов выборки.

Последовательность пар $(x_i^*; n_i)$, где $x_1^*, x_2^*, \dots, x_k^*$ – различные выборочные значения, а n_1, n_2, \dots, n_k – соответствующие им частоты, называется **статистическим рядом**. Обычно статистический ряд записывают в виде таблицы, первая строка которой содержит различные выборочные значения x_i^* , а вторая – их частоты n_i (или относительные частоты $\frac{n_i}{n}$, иногда и те, и другие).

В случае, когда число значений признака (СВ ξ) велико или признак является непрерывным (т. е. когда СВ ξ может принимать любое значение в некотором интервале), составляют **интервальный статистический ряд**. Для этого весь диапазон выборочных значений от x_{\min} до x_{\max} разбивают на k интервалов (обычно от 5 до 20; для определения количества интервалов можно использовать полуэмпирическую формулу Стерджесса $k \approx 1 + \log_2 n$) одинаковой длины $h = \frac{W}{k}$ и определяют частоты n_i – количество элементов выборки, попавших в i -й интервал (элемент, совпадающий с верхней границей интервала, относится к последующему интервалу). Полученные данные сводят в таблицу:

$[x_i; x_{i-1})$	$[x_0; x_1)$	$[x_1; x_2)$	\dots	$[x_{k-1}; x_k]$
$x_i^* = \frac{x_{i-1} + x_i}{2}$	x_1^*	x_2^*	\dots	x_k^*
n_i	n_1	n_2	\dots	n_k
$\frac{n_i}{n}$	$\frac{n_1}{n}$	$\frac{n_2}{n}$	\dots	$\frac{n_k}{n}$

Пусть выборка объема n представлена в виде интервального статистического ряда. Оценками для математического ожидания и дисперсии наблюдаемой случайной величины являются **выборочное среднее**

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i^* n_i$$

и **выборочная дисперсия**

$$D_B = \frac{1}{n} \sum_{i=1}^k (x_i^* - \bar{x})^2 n_i, \text{ или } D_B = \frac{1}{n} \sum_{i=1}^k (x_i^*)^2 n_i - (\bar{x})^2.$$

При этом выборочная дисперсия дает всегда немногого заниженную оценку для дисперсии, поэтому вместо нее используют несмешенную оценку дисперсии

$$s^2 = \frac{n}{n-1} D_B.$$

Эмпирической функцией распределения называется функция $F_n^*(x)$, определяющая для каждого значения x относительную частоту наблюдения значений, меньших x :

$$F_n^*(x) = \sum_{\substack{x_i^* < x \\ x_i^*}} \frac{n_i}{n}.$$

Гистограммой относительных частот называют ступенчатую фигуру, состоящую из прямоугольников, основаниями которых служат частичные интервалы длины h , а высоты равны $\frac{n_i}{nh}$. Площадь гистограммы относительных частот равна 1.

При достаточно большом объеме выборки n и достаточно малых интервалах группировки h гистограмма относительных частот является хорошим приближением графика плотности распределения наблюдаемой случайной величины. Поэтому по виду гистограммы можно выдвинуть предположение (гипотезу) о распределении изучаемой случайной величины.

Процедура сопоставления высказанного предположения (гипотезы) с выборочными данными называется **роверкой гипотез**.

Под **статистической гипотезой** понимают всякое высказывание (предположение) о виде (**непараметрическая гипотеза**) или параметрах (**параметрическая гипотеза**) неизвестного распределения. Статистическая гипотеза называется **простой**, если она полностью определяет функцию распределения. В противном случае гипотеза называется **сложной**.

Одну из гипотез выделяют в качестве **основной** (или **нулевой**) H_0 , а другую, являющуюся логическим отрицанием H_0 , – в качестве **конкурирующей** (или **альтернативной**) гипотезы \bar{H} .

Правило, по которому принимается решение принять или отклонить проверяемую гипотезу, называется **критерием проверки статистической гипотезы** (**статистическим критерием**). При этом заранее выбирают допустимое значение ошибки вывода, которое называется **уровнем значимости** статистического критерия и обозначается α (это вероятность отвергнуть нулевую гипотезу, когда она верна).

Статистические критерии, с помощью которых проверяются гипотезы о виде распределения, называются **критериями согласия** или **непараметрическими критериями**.

Критерий согласия χ^2 Пирсона. Пусть имеется выборка объема n и сгруппированный статистический ряд, в котором k групп. Например, в случае непрерывной СВ это будут k интервалов $[x_{i-1}; x_i)$.

Группы должны выбираться так, чтобы охватывать весь диапазон значений предполагаемой СВ. Если диапазон значений СВ не ограничен (к примеру, нормальная СВ принимает любые значения из $(-\infty; +\infty)$), то крайние интервалы должны быть расширены до $-\infty$ и $+\infty$ соответственно.

Кроме того, интервалы (группы) должны быть не очень маленькими, чтобы в каждый из них входило не менее 5 наблюдений. Группы с малым количеством наблюдений объединяют с соседними.

Проверяемая гипотеза представляет собой предположение о распределении наблюданной СВ и является простой (конкретно указывает предполагаемое распределение):

H_0 : функция распределения наблюданной СВ совпадает с $F(x)$;

\bar{H} : функция распределения наблюданной СВ не совпадает с $F(x)$.

Критерий согласия χ^2 Пирсона основан на сравнении эмпирических и теоретических частот попадания СВ в рассматриваемые группы (интервалы):

n_i – эмпирическая частота наблюдения значений из интервала $[x_{i-1}; x_i)$;

$np_i = n P(\xi \in [x_{i-1}; x_i)) = n(F(x_i) - F(x_{i-1}))$ – теоретическое значение соответствующей частоты.

Рассмотрим статистику

$$\chi^2_{\text{расч}} = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}.$$

Для вычисления статистики $\chi^2_{\text{расч}}$ нужно знать сгруппированный статистический ряд и теоретическую функцию распределения $F(x)$ для расчета вероятностей p_i . При этом теоретическое распределение $F(x)$ может зависеть от одного или нескольких параметров. В этом случае вместо значений параметров используются их оценки, рассчитанные по сгруппированному статистическому ряду *до объединения групп*.

Замечание. Контроль вычислений можно осуществить по формуле

$$\chi^2_{\text{расч}} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n.$$

Пусть r – число неизвестных параметров теоретического распределения, оцененных по выборке. **Критерий согласия χ^2 Пирсона** заключается в следующем: если $\chi^2_{\text{расч}} < \chi^2_{\alpha; k-r-1}$, где $\chi^2_{\alpha; k-r-1}$ определяется по таблице квантилей распределения χ^2 , то гипотеза H_0 принимается (признается непротиворечащей экспериментальным данным; нет оснований отвергнуть гипотезу H_0) на уровне значимости α , а если $\chi^2_{\text{расч}} \geq \chi^2_{\alpha; k-r-1}$, то гипотеза H_0 отвергается (не согласуется с данными эксперимента).

Основное достоинство критерия согласия χ^2 Пирсона – его универсальность, т. е. применимость для любого закона распределения, в том числе с неизвестными параметрами. Основной недостаток – необходимость большого объема выборки (не менее 60–100 наблюдений) и произвольность группировки, влияющая на величину $\chi^2_{\text{расч}}$.

Контрольные вопросы

1. Что называется выборкой? Что называется объемом выборки?
2. Что называется частотой выборочного значения? Что называется относительной частотой?
3. Как оценить по выборке математическое ожидание и дисперсию наблюдаемой СВ?
4. Как рассчитать несмешенную оценку дисперсии?
5. Как оценить по выборке функцию распределения и плотность распределения наблюдаемой СВ?
6. Что называется эмпирической функцией распределения?
7. Что называется гистограммой относительных частот?
8. Чему равна площадь гистограммы относительных частот?
9. Что называется статистической гипотезой?
10. В каком случае статистическая гипотеза называется простой? сложной?
11. В чем разница между нулевой и альтернативной гипотезами?
12. Что называется уровнем значимости статистического критерия?
13. Что называется критерием согласия?
14. В чем суть критерия согласия χ^2 Пирсона?
15. Какие достоинства и недостатки имеет критерий согласия χ^2 Пирсона?

Пример и методические указания по выполнению лабораторной работы в Excel

1. Составить интервальный статистический ряд.

Величину интервалов округлить с точностью до 0,1 в большую сторону.

2. Найти эмпирическую функцию распределения и построить ее график.

3. Построить гистограмму относительных частот.

Можно ли предположить, что данная выборка взята из нормального распределения?

4. Определить выборочное среднее и несмешенную оценку дисперсии по сгруппированному статистическому ряду.

5. Записать предполагаемую плотность закона распределения.

6. Проверить по критерию χ^2 Пирсона гипотезу о законе распределения.

Уровень значимости принять равным $\alpha = 0,05$.

37	34	42	38	31	41	40	35	32	34
37	37	26	39	45	37	40	40	45	31
39	42	47	37	42	40	29	35	40	36
34	33	31	28	37	40	41	41	49	41
37	29	43	43	39	35	42	42	39	50
31	33	38	42	38	35	32	37	45	42
44	34	34	34	38	38	38	30	39	35
42	33	35	31	35	53	48	39	47	41
37	48	41	43	42	29	33	48	39	42
41	41	36	43	37	33	38	43	37	34

1. Объем выборки $n = 100$.

Построим интервальный статистический ряд.

Количество интервалов определим по формуле Стерджесса
 $k \approx 1 + \log_2 n = 1 + \log_2 100 = 7,644$. Принимаем $k = 8$.

Размах выборки $W = x_{\max} - x_{\min} = 53 - 26 = 27$.

Длина каждого интервала будет $h \approx \frac{W}{k} = \frac{27}{8} = 3,375$. Округлив с точностью до 0,1 в большую сторону, принимаем $h = 3,4$.

Находим количество элементов выборки в каждом интервале.

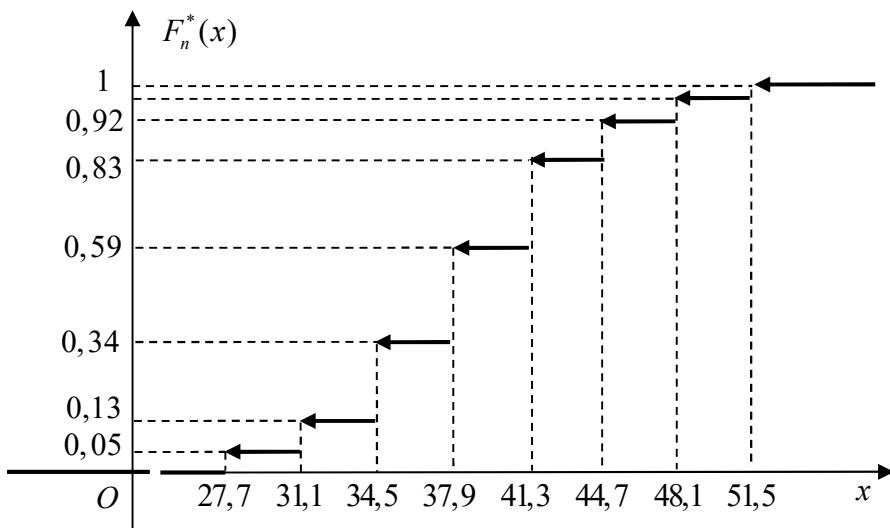
$[x_i; x_{i-1})$	x_i^*	n_i	$\frac{n_i}{n}$	$\frac{n_i}{nh}$
[26; 29,4)	27,7	5	0,05	0,015
[29,4; 32,8)	31,1	8	0,08	0,024
[32,8; 36,2)	34,5	21	0,21	0,062
[36,2; 39,6)	37,9	25	0,25	0,074
[39,6; 43)	41,3	24	0,24	0,071
[43; 46,4)	44,7	9	0,09	0,026
[46,4; 49,8)	48,1	6	0,06	0,018
[49,8; 53,2]	51,5	2	0,02	0,006

2. Для построения эмпирической функции распределения и гистограммы относительных частот дополним интервальный статистический ряд столбцами $\frac{n_i}{n}$ (относительные частоты нужны для построения эмпирической функции распределения) и $\frac{n_i}{nh}$ (высоты прямоугольников гистограммы).

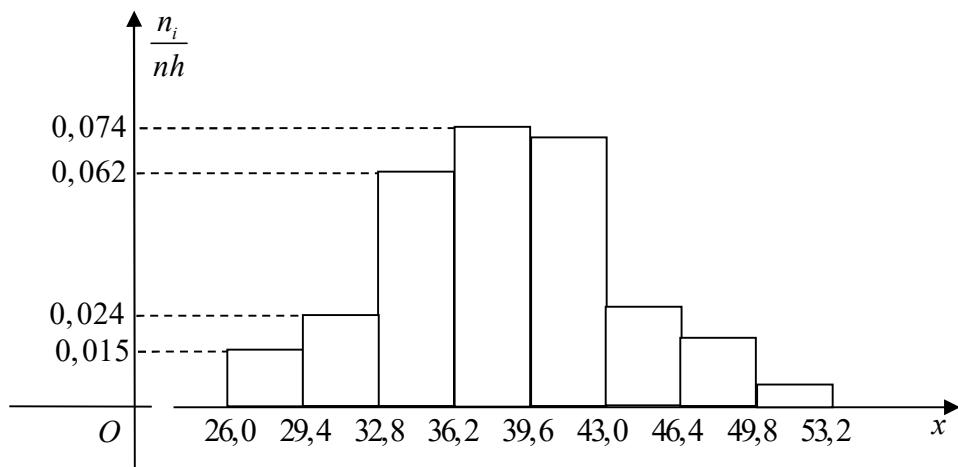
Запишем эмпирическую функцию распределения, накапливая относительные частоты $\frac{n_i}{n}$ (отметим, что при построении эмпирической функции распределения по интервальному статистическому ряду изменения ее значений (скачки) происходят в точках, соответствующих серединам интервалов группировки):

$$F_n^*(x) = \begin{cases} 0 & \text{при } x \leq 27,7, \\ 0,05 & \text{при } 27,7 < x \leq 31,1, \\ 0,13 & \text{при } 31,1 < x \leq 34,5, \\ 0,34 & \text{при } 34,5 < x \leq 37,9, \\ 0,59 & \text{при } 37,9 < x \leq 41,3, \\ 0,83 & \text{при } 41,3 < x \leq 44,7, \\ 0,92 & \text{при } 44,7 < x \leq 48,1, \\ 0,98 & \text{при } 48,1 < x \leq 51,5, \\ 1 & \text{при } x > 51,5. \end{cases}$$

Построим график $F_n^*(x)$.



3. Гистограмма относительных частот состоит из прямоугольников шириной $h = 3,4$ и высотой $\frac{n_i}{nh}$.



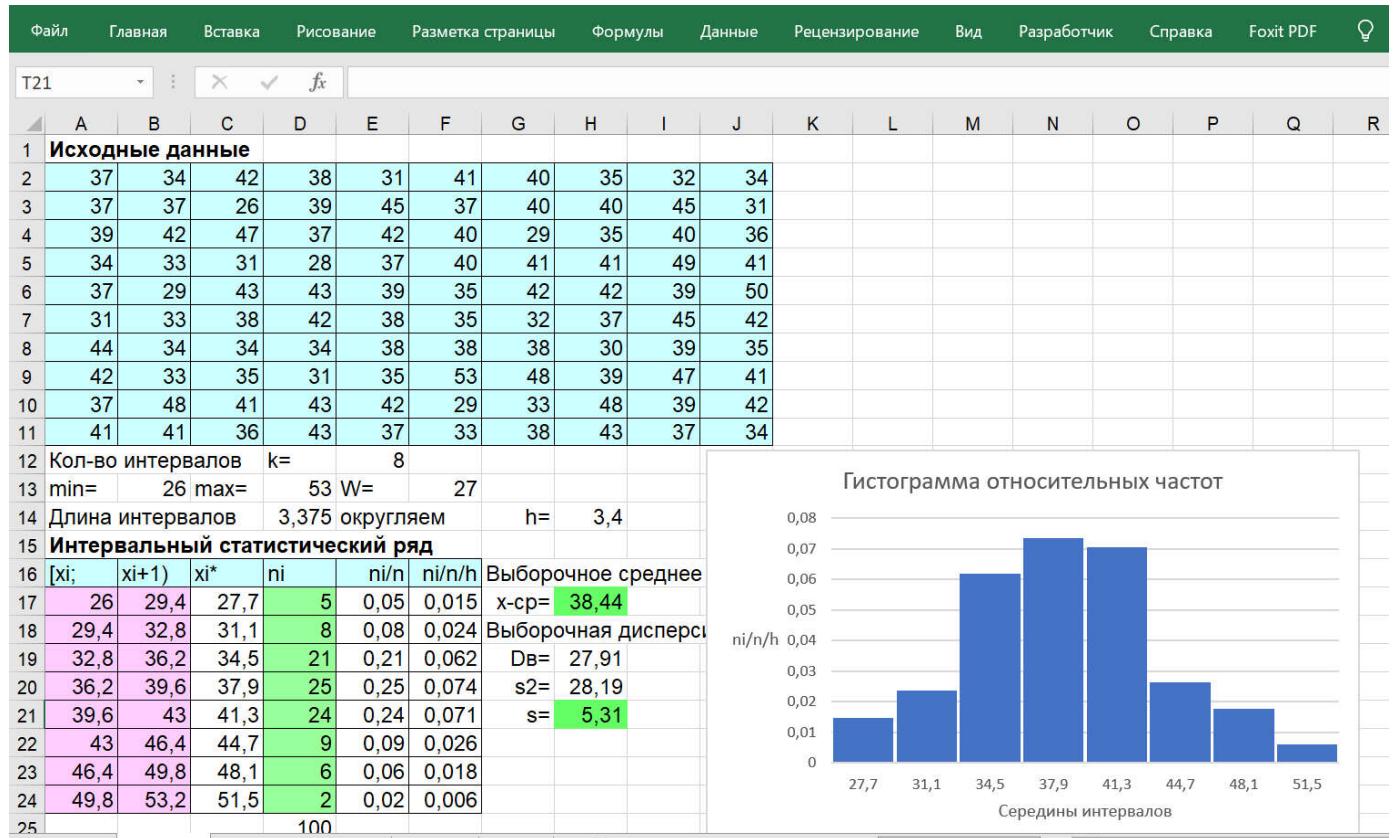
По виду гистограммы можно выдвинуть гипотезу о том, что выборка взята из нормального распределения. Для проверки этой гипотезы по критерию согласия χ^2 Пирсона нужно рассчитать оценки параметров распределения по сгруппированному статистическому ряду.

Ниже даны рекомендации по выполнению пунктов 1, 3 в Excel и приведен фрагмент рабочего листа.

Методические указания по использованию EXCEL

- E** 1. 1) Функции МИН() и МАКС() находят наименьшее и наибольшее значения из заданных. *Например*, в ячейке B13 записана формула =МИН(A2:J11)
- X** 2) Функция ОКРВВЕРХ() округляет значение до ближайшего большего с заданной точностью. *Например*, в ячейке H14 использована формула =ОКРВВЕРХ(D14;0,1)
- C** 3) Функция СЧЁТЕСЛИМН() используется для подсчета количества ячеек, удовлетворяющих нескольким заданным условиям. *Например*, формула в ячейке D17 имеет вид
- =СЧЁТЕСЛИМН(\$A\$2:\$J\$11;">=&A17;\$A\$2:\$J\$11;"<"&B17)

L 3. Для построения гистограммы относительных частот используется вкладка Вставка → Диаграмма.



4. Рассчитаем оценки параметров предполагаемого нормального закона распределения по сгруппированному статистическому ряду. Данный закон содержит два параметра a и σ , которые имеют смысл математического ожидания и среднего квадратического отклонения СВ ξ : $M\xi = a$, $D\xi = \sigma^2$.

В качестве оценок для математического ожидания a и дисперсии σ^2 наблюдаемой случайной величины рассчитаем соответственно выборочное среднее \bar{x} и несмешенную оценку дисперсии s^2 , для вычисления s^2 предварительно найдем выборочную дисперсию D_b :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i^* n_i;$$

$$D_b = \frac{1}{n} \sum_{i=1}^k (x_i^*)^2 n_i - (\bar{x})^2;$$

$$s^2 = \frac{n}{n-1} D_b.$$

Используя интервальный статистический ряд, получим:

$$\begin{aligned} \bar{x} &= \frac{1}{100} \cdot (27,7 \cdot 5 + 31,1 \cdot 8 + 34,5 \cdot 21 + 37,9 \cdot 25 + 41,3 \cdot 24 + \\ &\quad + 44,7 \cdot 9 + 48,1 \cdot 6 + 51,5 \cdot 2) \approx 38,44; \end{aligned}$$

$$D_b = \frac{1}{100} \cdot (27,7^2 \cdot 5 + 31,1^2 \cdot 8 + 34,5^2 \cdot 21 + 37,9^2 \cdot 25 + 41,3^2 \cdot 24 +$$

$$+44,7^2 \cdot 9 + 48,1^2 \cdot 6 + 51,5^2 \cdot 2) - 38,44^2 \approx 27,91;$$

$$s^2 = \frac{100}{99} \cdot 27,91 \approx 28,19.$$

Тогда оценкой для среднего квадратического отклонения σ будет $s = \sqrt{28,19} \approx 5,31$.

5. Функция плотности нормального закона распределения имеет вид

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-a)^2}{2\sigma^2}}.$$

Следовательно, выдвигаем гипотезу:

H_0 : выборка взята из нормального распределения с плотностью

$$f(x) = \frac{1}{5,31\sqrt{2\pi}} e^{-\frac{(x-38,44)^2}{56,38}}.$$

Методические указания по использованию EXCEL

- E**
X
C
E
L
- 4. 1) Функция СУММПРОИЗВ() вычисляет сумму произведений элементов двух или нескольких массивов. Например, в ячейке G16 записана формула $=СУММПРОИЗВ(С17:С24;D17:D24)/100$
 - 2) Функция КОРЕНЬ() извлекает квадратный корень.

6. Проверим с помощью критерия согласия χ^2 Пирсона гипотезу

H_0 : наблюдаемая СВ имеет нормальное распределение с параметрами $a = 38,44$, $\sigma = 5,31$

при альтернативе

H_1 : наблюдаемая СВ имеет другое распределение.

Для расчета статистики критерия Пирсона

$$\chi_{\text{расч}}^2 = \sum_{i=1}^k \frac{(n_i - np_i)^2}{np_i}$$

составим новую таблицу, содержащую следующие столбцы:

- интервалы $[x_{i-1}; x_i)$ (при этом крайние интервалы должны быть расширены до $-\infty$ и $+\infty$ соответственно; а интервалы с количеством наблюдений меньше 5 объединяются с соседними);
- n_i – эмпирическая частота наблюдения значений из интервала $[x_{i-1}; x_i)$;
- $p_i = P(\xi \in [x_{i-1}; x_i))$ – теоретическая вероятность попадания СВ в интервал $[x_{i-1}; x_i)$, в случае нормального распределения с параметрами $a = 38,44$, $\sigma = 5,31$ эта вероятность рассчитывается как разность значений функции Лапласа:

$$p_i = \Phi\left(\frac{x_i - 38,44}{5,31}\right) - \Phi\left(\frac{x_{i-1} - 38,44}{5,31}\right);$$

- np_i – теоретическое значение соответствующей частоты,
- а также столбцы со значениями $n_i - np_i$, $(n_i - np_i)^2$, $\frac{(n_i - np_i)^2}{np_i}$, $\frac{n_i^2}{np_i}$.

Последний столбец используется для контроля вычислений по формуле

$$\chi^2_{\text{расч}} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n.$$

Все вычисления заносим в таблицу.

Интервалы	n_i	p_i	np_i	$n_i - np_i$	$(n_i - np_i)^2$	$\frac{(n_i - np_i)^2}{np_i}$	$\frac{n_i^2}{np_i}$
[-∞; 29,4)	5	0,0443	4,425	0,575	0,33	0,075	5,649
[29,4; 32,8)	8	0,0996	9,964	-1,96	3,858	0,387	6,423
[32,8; 36,2)	21	0,1924	19,24	1,761	3,103	0,161	22,92
[36,2; 39,6)	25	0,2499	24,99	0,011	0,0001	0,000	25,01
[39,6; 43)	24	0,2184	21,84	2,16	4,668	0,214	26,37
[43; 46,4)	9	0,1284	12,84	-3,84	14,76	1,149	6,308
[46,4; +∞)	8	0,067	6,701	1,299	1,686	0,252	9,55
Суммы	100	1	100		$\chi^2_{\text{расч}} = 2,2376$		102,24

Сумма элементов последнего столбца равна $\sum_{i=1}^k \frac{n_i^2}{np_i} \approx 102,24$. Контроль вычислений: $\chi^2_{\text{расч}} = \sum_{i=1}^k \frac{n_i^2}{np_i} - n = 102,24 - 100 = 2,24$.

Определим критическое значение $\chi^2_{\text{крит}} = \chi^2_{\alpha; k-r-1}$, где $\alpha = 0,05$ – заданный уровень значимости; $k = 7$ – число интервалов после объединения малочисленных групп с соседними; $r = 2$, поскольку при расчете теоретических вероятностей p_i использовались две полученные по выборке оценки \bar{x} и s параметров нормального распределения. По таблице квантилей распределения χ^2 получаем $\chi^2_{\text{крит}} = \chi^2_{0,05; 4} = 9,4877$.

Таким образом, $\chi^2_{\text{расч}} = 2,24 < \chi^2_{\text{крит}} = 9,4877$, поэтому на уровне значимости $\alpha = 0,05$ нет оснований отвергнуть гипотезу H_0 , согласно которой выборка взята из нормального распределения с параметрами $a = 38,44$, $\sigma = 5,31$.

Ниже даны рекомендации по выполнению пункта 6 в Excel и приведен фрагмент рабочего листа.

Методические указания по использованию EXCEL

E 6. 1) Таблица, помогающая рассчитать значение критерия $\chi^2_{\text{расч}}$, расположена в ячейках A27:G36, поскольку понадобилось присоединить последний интервал, содержащий всего 2 наблюдения, к предыдущему, в результате чего число интервалов сократилось.

C Помните, что при использовании критерия χ^2 Пирсона интервалы с числом наблюдений $n_i < 5$ объединяют с соседними.

2) Учтите, что первый интервал нужно продлить до $-\infty$, а последний —

E до $+\infty$.
L 3) Функция
H НОРМ.РАСП(x ;среднее;стандартное откл;интегральная)
X вычисляет значение функции нормального распределения
 $F(x) = 0,5 + \Phi\left(\frac{x - a}{\sigma}\right)$. Здесь x — значение, для которого вычисляется

E значение функции, среднее — математическое ожидание a (задаем
X выборочное среднее \bar{x}), стандартное откл — среднеквадратическое
C отклонение σ (задаем s), интегральная — логическое значение,
L определяющее форму функции. Для того чтобы получить нужное значение
E интегральной функции распределения, задаем Истинна.
L Если задать значение Ложь, то получится значение плотности
C нормального распределения.

E Например, в ячейке D29 использована формула

=НОРМ.РАСП(В29;\$H\$17;\$H\$21;ИСТИНА)-

НОРМ.РАСП(А29;\$H\$17;\$H\$21;ИСТИНА)

L 4) Функция ХИ2.ОБР.ПХ() вычисляет квантиль распределения χ^2
E (табличное значение $\chi^2_{\text{крит}}$). Например, в ячейке H37 записана формула
L =ХИ2.ОБР.ПХ(0,05;E37)

